1. Pendahuluan

Tuberkulosis (TB) merupakan penyakit infeksi menular yang disebabkan oleh *Mycobacterium tuberculosis* dan masih menjadi salah satu penyebab utama kematian akibat penyakit menular di dunia (World Health Organization, 2023). Penyakit ini terutama menyerang paru-paru sebagai pulmonary TB (PTB), namun juga dapat mengenai organ lain sebagai extra-pulmonary TB (EPTB) (Pai et al., 2016).

Respons imun terhadap infeksi *M. tuberculosis* melibatkan aktivasi makrofag, sel T, serta produksi berbagai sitokin proinflamasi. Proses ini diikuti oleh perubahan ekspresi gen yang berperan dalam mekanisme pertahanan inang dan proses inflamasi (O'Garra et al., 2013). Perubahan ekspresi gen tersebut dapat dipelajari melalui pendekatan transcriptomics untuk memahami mekanisme patogenesis serta respons imun terhadap TB (Berry et al., 2010).

Analisis ekspresi gen berbasis transcriptomics memungkinkan identifikasi differentially expressed genes (DEGs) yang berperan dalam perkembangan penyakit. Dengan membandingkan profil ekspresi gen antara pasien TB aktif dan individu sehat, dapat diidentifikasi gen yang berpotensi menjadi biomarker diagnosis maupun target terapi (Zak et al., 2016).

Berdasarkan hal tersebut, analisis ini bertujuan untuk mengidentifikasi gen-gen yang berbeda ekspresinya antara pasien TB aktif (gabungan PTB dan EPTB) dan kontrol sehat menggunakan dataset GSE83456 melalui platform GEO2R.

2. Metode

2.1 Sumber Data

Data ekspresi gen yang digunakan dalam penelitian ini diperoleh dari database publik National Center for Biotechnology Information (NCBI) melalui repositori Gene Expression Omnibus (GEO) dengan nomor akses GSE83456. Dataset ini berasal dari platform mikroarray Illumina HumanHT-12 V4.0 expression beadchip (GPL10558). Data tersebut berisi profil ekspresi gen dari sampel darah manusia yang terdiri dari kelompok pasien tuberkulosis aktif dan kelompok kontrol sehat.

2.2 Pengolahan dan Analisis Data

Analisis data dilakukan menggunakan perangkat lunak R dengan beberapa paket bioinformatika dari Bioconductor. Data mikroarray diunduh secara langsung dari GEO menggunakan paket GEOquery dalam format *ExpressionSet* yang berisi matriks ekspresi gen, metadata sampel, dan informasi probe.

Nilai ekspresi gen kemudian diekstraksi menggunakan fungsi exprs(). Untuk memastikan distribusi data sesuai dengan asumsi model statistik, dilakukan evaluasi transformasi logaritma basis dua (log2). Transformasi log2 diterapkan apabila rentang nilai ekspresi terlalu besar, sehingga dapat menstabilkan varians data serta mempermudah interpretasi perubahan ekspresi gen (*log fold change*).

2.3 Analisis Differentially Expressed Genes (DEG)

Analisis gen yang diekspresikan secara berbeda antara kelompok tuberkulosis dan kontrol sehat dilakukan menggunakan paket limma. Metode ini menggunakan pendekatan model linear untuk setiap gen pada matriks ekspresi.

Pertama, dibuat *design matrix* untuk merepresentasikan kelompok sampel. Selanjutnya, model linear dibangun menggunakan fungsi lmFit() dan perbandingan antar kelompok ditentukan melalui fungsi makeContrasts(). Model kemudian disesuaikan menggunakan contrasts.fit() dan dianalisis dengan metode *empirical Bayes* melalui fungsi eBayes() untuk meningkatkan stabilitas estimasi varians.

Gen yang dianggap berbeda secara signifikan ditentukan menggunakan fungsi topTable() dengan kriteria nilai *adjusted p-value* (FDR) < 0,01. Metode koreksi *False Discovery Rate* digunakan untuk mengurangi kemungkinan kesalahan akibat pengujian multipel.

2.4 Anotasi Gen

Karena data mikroarray berbasis probe, identitas gen perlu dipetakan kembali dari ID probe ke simbol gen. Proses anotasi dilakukan menggunakan paket illuminaHumanv4.db dengan bantuan paket AnnotationDbi. Melalui proses ini, setiap probe dipetakan ke informasi simbol gen (*gene symbol*) dan nama gen (*gene name*).

2.5 Visualisasi Data

Beberapa metode visualisasi digunakan untuk mengevaluasi kualitas data dan menginterpretasikan hasil analisis.

Distribusi nilai ekspresi gen antar sampel divisualisasikan menggunakan boxplot untuk memastikan keseragaman distribusi data. Selain itu, *density plot* digunakan untuk melihat pola distribusi global nilai ekspresi gen.

Untuk mengeksplorasi struktur data secara keseluruhan, dilakukan reduksi dimensi menggunakan metode Uniform Manifold Approximation and Projection (UMAP) sehingga ribuan variabel gen dapat direpresentasikan dalam dua dimensi.

Hasil analisis gen diferensial kemudian divisualisasikan menggunakan volcano plot yang menampilkan hubungan antara perubahan ekspresi gen (*log fold change*) dan

tingkat signifikansi statistik. Selain itu, pola ekspresi gen yang paling signifikan ditampilkan menggunakan heatmap dengan memilih 50 gen dengan nilai *adjusted p-value* paling kecil.

2.6 Penyimpanan Hasil Analisis

Seluruh hasil analisis, termasuk daftar gen yang diekspresikan secara berbeda, disimpan dalam format file CSV untuk memudahkan analisis lanjutan dan dokumentasi penelitian.

3. Hasil dan Interpretasi

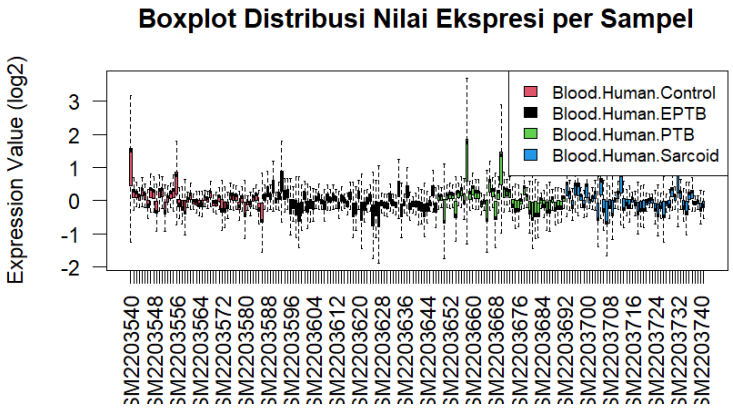

Berdasarkan boxplot distribusi nilai ekspresi per sampel, terlihat bahwa sebagian besar sampel memiliki pola distribusi ekspresi gen yang relatif serupa setelah proses normalisasi data. Median dan rentang nilai ekspresi antar sampel berada pada kisaran yang hampir sama, yang menunjukkan bahwa proses normalisasi berhasil mengurangi variasi teknis antar sampel. Hal ini penting karena memastikan bahwa perbedaan yang diamati pada analisis selanjutnya lebih merepresentasikan variasi biologis daripada artefak teknis.

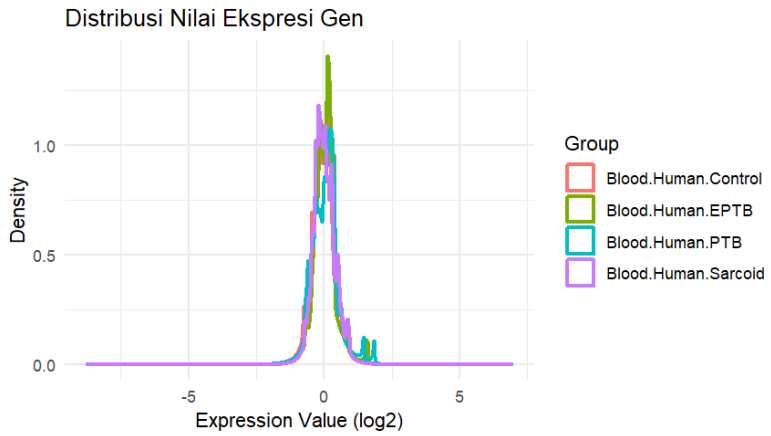

Distribusi nilai ekspresi gen yang ditunjukkan melalui density plot memperlihatkan pola distribusi yang hampir tumpang tindih antar kelompok sampel. Kurva distribusi yang relatif simetris dan memiliki puncak pada kisaran nilai yang sama menunjukkan bahwa sebagian besar gen memiliki tingkat ekspresi yang konsisten di antara kelompok kontrol maupun kelompok penyakit. Hal ini mengindikasikan bahwa kualitas data cukup baik dan tidak terdapat penyimpangan distribusi yang signifikan antar kelompok.

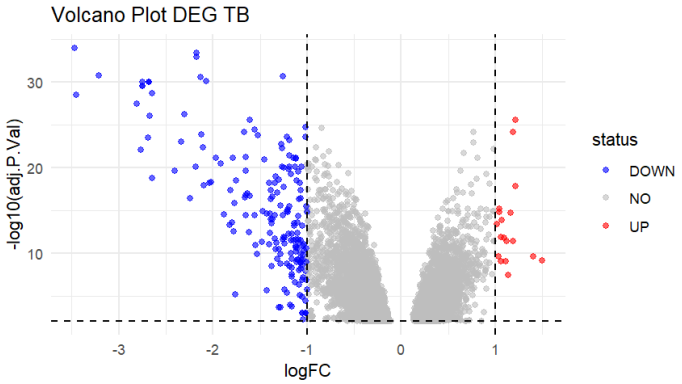

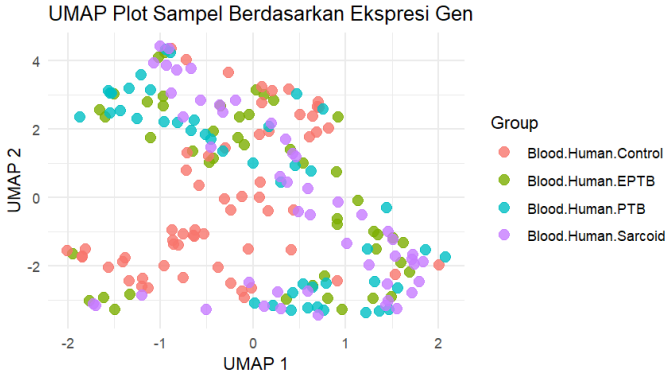

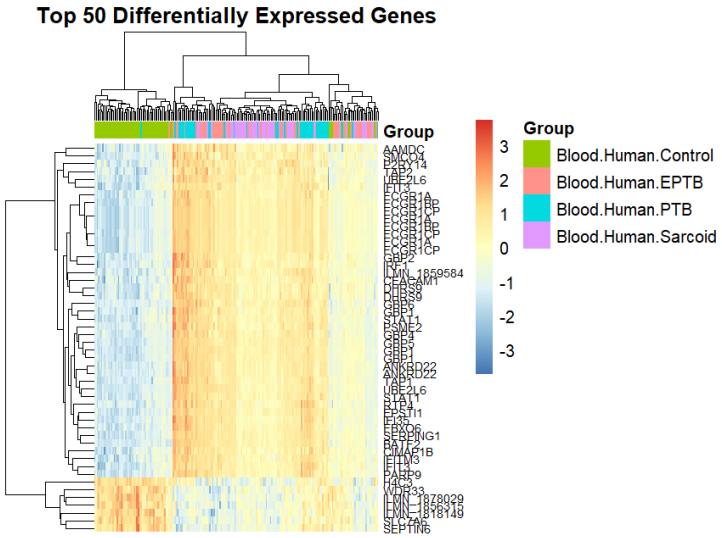

Visualisasi menggunakan UMAP (Uniform Manifold Approximation and Projection) menunjukkan pengelompokan sampel berdasarkan pola ekspresi gen.

Meskipun terdapat beberapa area yang saling tumpang tindih, beberapa sampel mulai membentuk klaster tertentu sesuai dengan kelompok biologisnya. Hal ini menunjukkan adanya kecenderungan perbedaan profil ekspresi gen antara kelompok kontrol, PTB, EPTB, dan sarkoidosis, meskipun pemisahan antar kelompok belum sepenuhnya jelas. Selanjutnya, heatmap dari 50 gen dengan ekspresi diferensial tertinggi menunjukkan pola ekspresi gen yang berbeda antar kelompok sampel. Warna merah pada heatmap menunjukkan gen yang mengalami peningkatan ekspresi (upregulated), sedangkan warna biru menunjukkan penurunan ekspresi (downregulated). Pola klaster pada heatmap memperlihatkan bahwa beberapa gen memiliki ekspresi yang konsisten meningkat atau menurun pada kelompok penyakit dibandingkan kelompok kontrol. Hal ini mengindikasikan adanya gen-gen tertentu yang berpotensi berperan dalam mekanisme biologis yang mendasari kondisi penyakit yang dianalisis.

Secara keseluruhan, hasil analisis ini menunjukkan adanya variasi ekspresi gen yang dapat membedakan kelompok sampel secara biologis. Identifikasi gen-gen dengan ekspresi diferensial tersebut dapat menjadi dasar untuk analisis lanjutan, seperti analisis fungsi gen, jalur biologis (pathway analysis), maupun pencarian biomarker potensial yang berkaitan dengan penyakit yang diteliti.